

## Tarea 2

### P1) Demuestre la Proposición 7.42 del libro

Demostrar que  $\forall S \in \mathcal{L}(V, W)$  con  $\dim(\text{range}(S)) \leq k$  se cumple que:

$$\|T - S\| \geq \sigma_{k+1}$$

Por el Teorema de Descomposición de Valores Singulares,  $\exists$  bases ortonormales  $e_1, \dots, e_n$  de  $V$  y  $f_1, \dots, f_m$  de  $W$  tales que:

$$Tv = \sum_{j=1}^r \sigma_j \langle v, e_j \rangle f_j$$

donde  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$ .

Defino un subespacio,  $S \in \mathcal{L}(V, W) : \dim(\text{range}(S)) \leq k$ .  
 $U \subseteq V$  :

$$U = \text{span}(e_1, e_2, \dots, e_{k+1})$$

Como  $e_j$  son L.I., la dimensión de  $U = k + 1$ .

Por el Teorema de la Dimensión:

Considerando  $S|_U : U \rightarrow W$

$$\dim(\text{Null}(S|_U)) + \dim(\text{range}(S|_U)) = \dim(U)$$

Como el rango de  $S|_U$  no puede ser mayor al rango de  $S$ :

$$\dim(\text{range}(S|_U)) \leq \dim(\text{range}(S)) \leq k$$

Reemplazándolo en el Teorema de la Dimensión:

$$\dim(\text{null}(S|_U)) \geq (k + 1) - k = 1$$

Por lo tanto, existe un vector  $v \in U$  tal que  $\|v\| = 1$  y  $Sv = 0$ . Como  $v \in U$ :

$$v = \sum_{j=1}^{k+1} c_j e_j, \quad \text{donde} \quad \sum_{j=1}^{k+1} |c_j|^2 = 1$$

Evaluando la norma del operador  $T - S$  en el vector  $v$ :

$$\|(T - S)v\|^2 = \|Tv - Sv\|^2 = \|Tv - 0\|^2 = \|Tv\|^2$$

Aplicando  $T$  a  $v$ :

$$\|Tv\|^2 = \left\| \sum_{j=1}^{k+1} c_j \sigma_j f_j \right\|^2 = \sum_{j=1}^{k+1} \sigma_j^2 |c_j|^2 \geq \sigma_{k+1}^2 \sum_{j=1}^{k+1} |c_j|^2 = \sigma_{k+1}^2$$

Como encontramos un vector unitario  $v$  tal que  $\|(T - S)v\| \geq \sigma_{k+1}$ , y la norma de  $\|T - S\|$  por definición es el supremo de todos los vectores unitarios, concluimos que:

$$\|T - S\| \geq \sigma_{k+1}$$

## P2) Análisis de Componentes Principales (PCA) mediante SVD

En esta sección se presentan el desarrollo, las conclusiones y los resultados gráficos obtenidos al aplicar la Descomposición en Valores Singulares (SVD) sobre el conjunto de datos MNIST.

### 1. Varianza Explicada Acumulada

**Conclusión:** La curva presenta una pendiente inicial bastante pronunciada, lo que refleja una alta redundancia espacial en las imágenes de dígitos de MNIST. Se observa que para explicar el 90% de la varianza total se requieren únicamente  $k = 84$  componentes, mientras que para alcanzar el 99% se necesitan  $k = 322$ . Esto demuestra la efectividad de SVD/PCA para la reducción de dimensionalidad conservando la información esencial.

### 2. Visualización de la Imagen Promedio y Eigen-imágenes

**Conclusión:** La imagen promedio muestra un trazo difuso que comparte características geométricas básicas de dígitos comunes como el "0", el "8" o el "3". Las primeras eigen-imágenes capturan las variaciones más significativas de baja frecuencia (formas generales, inclinación del trazo y grosor), mientras que las componentes más avanzadas empiezan a modelar detalles finos específicos de cada muestra.

### 3. Reconstrucción Progresiva de un Dígito

**Conclusión:** Con un número muy bajo de componentes ( $k \leq 5$ ), la imagen reconstruida es sumamente borrosa e irreconocible debido a la pérdida de información de alta frecuencia. Sin embargo, al alcanzar  $k = 20$ , las características y el contorno del dígito se vuelven plenamente identificables. Para valores de  $k \geq 100$ , la reconstrucción es prácticamente idéntica a la original, confirmando que el error disminuye rápidamente al agregar términos a la SVD truncada.

## Resultados Gráficos

A continuación se presentan las figuras correspondientes a cada uno de los análisis descritos anteriormente:




Figura 1: Gráfico de la varianza acumulada vs número de componentes principales.




Figura 2: Visualización de la imagen promedio y las primeras 10 Eigen-imágenes.




Figura 3: Efecto en la calidad de la reconstrucción del dígito conforme se incrementa  $k$ .

Link del repositorio: <https://github.com/OeMachucabo/Tarea-2-Algebra>